實驗一

前處理

一、圖片轉換

這邊針對圖片做一些差異化處理，以下是其處理細節:

1. ‘transforms.RandomResizedCrop(224)‘: 這個轉換隨機對圖像進行裁剪和縮放，使圖像的大小變為 224x224 像素，幫助模型更好地適應不同尺寸的輸入圖像。

2. ‘transforms.RandomHorizontalFlip()‘:隨機水平翻轉的轉換，以增加數據的多樣性。

3. ‘transforms.RandomRotation(30)‘: 這個轉換隨機旋轉圖像，最多旋轉 30 度。

4. ‘transforms.ToTensor()‘: 這個轉換將圖像轉換為 PyTorch 張量格式。

5. ‘transforms.Normalize(mean=train_mean, std=train_std)‘: 這個轉換對圖像進行正則化，通過減去平均值（mean）並除以標準差（std)。這是我計算自訓練集。

二、設置分割

Batch 設置為 64

模型設計

一、初始特徵提取

這裡首先定義了一個初始的卷積層，這個卷積層對輸入影像進行處理。具體來說，它有以下特點：

1. ‘nn.Conv2d(3, 32, kernel_size=7, stride=2, padding=3)‘：這是一個卷積層，輸入通道數為 3（RGB 彩色影像），輸出通道數為 32，卷積核大小為 7x7，步幅（stride）為 2，填充（padding）為 3。這個卷積層負責對輸入影像進行初步特徵提取，並降低影像的尺寸。

2. ‘nn.BatchNorm2d(32)‘：接著是一個批量標準化層，用來穩定神經網路的訓練，防止梯度消失或爆炸的問題。

3. ‘nn.RELU()‘：採用 RELU 激活函數，用來引入非線性性質到網絡中。

二、IBConv Blocks

接下來，定義了一系列的 Inverted Bottleneck Convolution Blocks。我是閱讀自資料參考一。每個區塊有不同的輸入和輸出通道數，以及卷積核的設定。這些區塊可以用於提取更高級的特徵。

三、Fully connected layers

在卷積部分之後，定義了幾個全連接層，這些層通常用於將卷積層的輸出映射到最終的輸出分類。具體來說，這裡有以下層次：

1. ‘nn.Linear(80, 512)‘：一個全連接層，將卷積部分的輸出映射到 512 維的特徵向量。
2. ‘nn.RELU()‘：再次使用 RELU 激活函數。
3. ‘nn.BatchNorm1d(512)‘：批量標準化層，用於穩定訓練過程。
4. ‘nn.Dropout()‘：Dropout 層，用於隨機丟棄部分神經元，以防止過度擬合，機率設置為 0.5。

四、Output layer

最後，使用一個全連接層‘nn.Linear(512, 5)‘ 作為輸出層，輸出 5 個類別的分類結果。

五、訓練方法

1. 增加‘early_stopping_patience‘ 是用來設定早停機制的參數，即在連續 20 個輪次中如果驗證損失不再改善就提前停止訓練。
2. 使用 Adam 優化法，設置權重衰減 0.0001。
3. 學習率設置為 0.001

六、標記未標註資料加強準確度

1. 將偽標籤設置需要 0.85 臨界點來標記
2. 使用 Adam 優化法，設置權重衰減 0.001。
3. 學習率設置為 0.0001

總結：

1. 採用 Inverted Bottleneck Convolution Blocks，來提升訓練效率，對比低深度高 Channel 能達到更好效率 (9s/Epoch with 3060 GPU)。
2. 採用 Adam 達到更快訓練。
3. 由正規化技術 Batch-Normalize、搭配 Dropout、權重衰減，以及訓練時 Early-Stopping，以避免過度擬合。
4. 在使用未標記資料訓練時提高權重衰減，並降低學習率

實驗結果:

測定獲取: 0.75694 測試準確度，對比訓練 0.82 準確度，代表泛度仍須提升

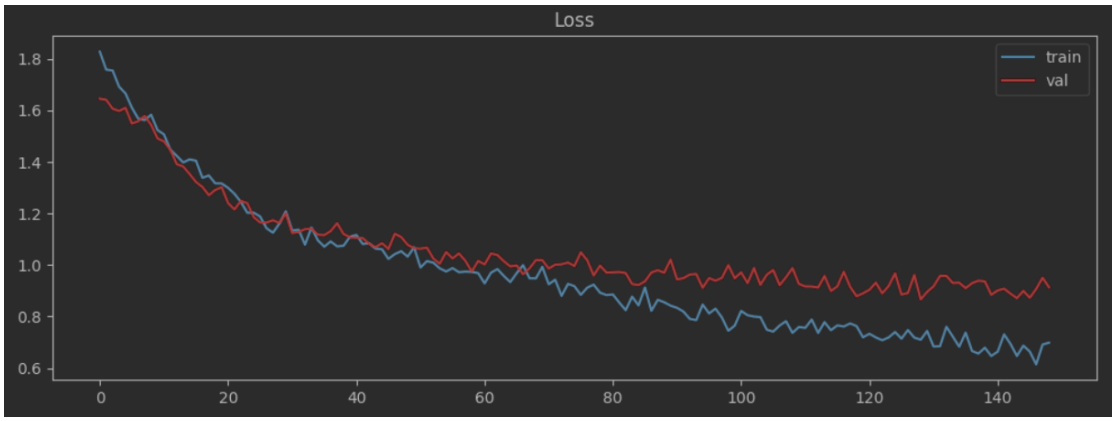

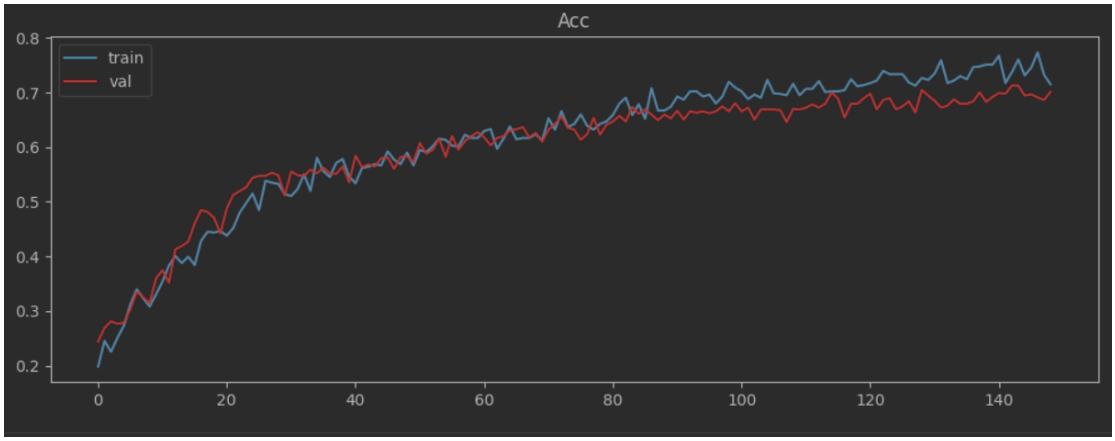

實驗二

前處理

設置分割

變更 Batch 設置為 32

模型設計

激活函數變更

將全部激活函數變更為‘nn.SELU()‘，觀測結果與出對比用

總結：

1. 我將對比 Selu 與 Relu 的差異，我認為對我的架構上有些許提升，但是賞需多次實驗度比
2. 較小的 Batch 似乎能提升泛度
3. 總一成效提升 4.3%

實驗結果:

測定獲取: 0.80092 測試準確度，對比訓練 0.83 準確度，有顯著提升，說明在該設計使用 Selu 具有較好成效

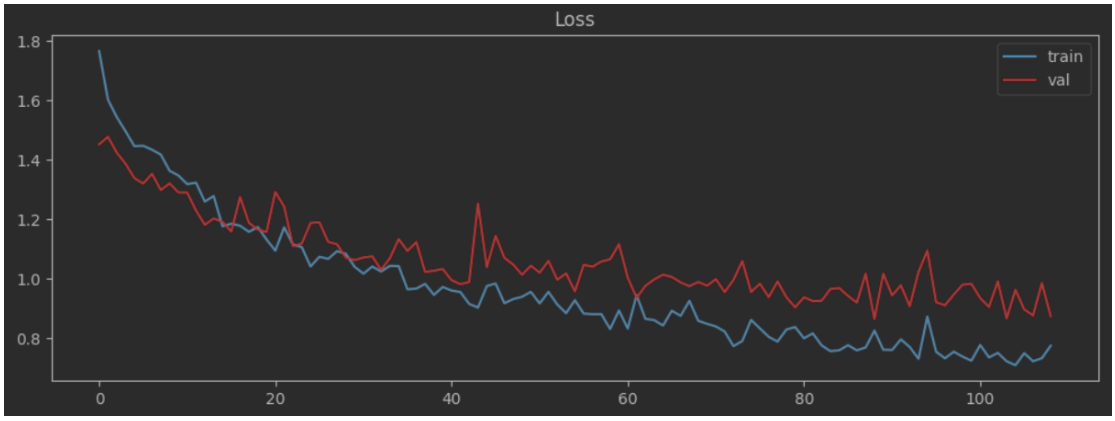

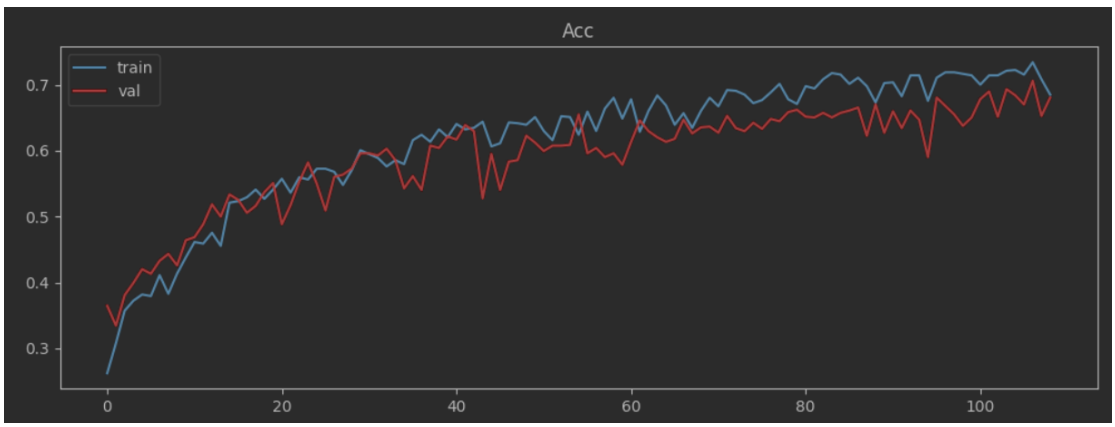

實驗三

前處理

圖片轉換

1. 更新訓練集的平均值與標準差
2. 去除干擾性訓練資料

總結：

移除干擾資料後，我的模型成效下降 0.7%

實驗結果:

測定獲取: 0.793262 驗證準確度，對比訓練 0.83 準確度，測試 0.7723，代表有過度擬合跡象

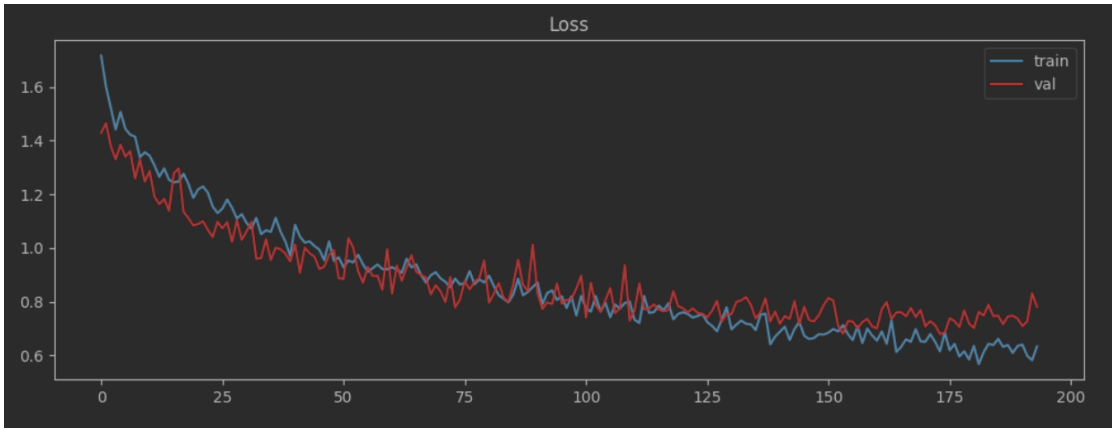

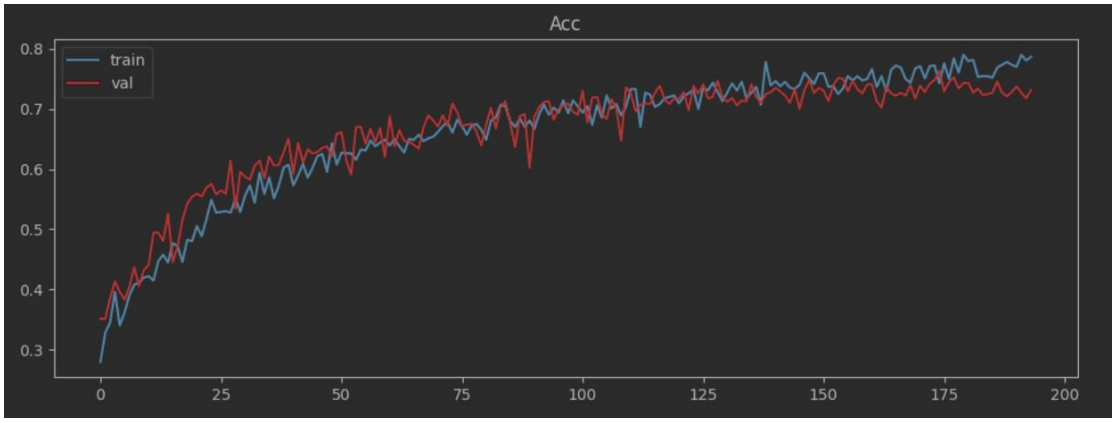

備註: 早停會回朔參數到最後儲存最佳準確驗證模型的參數

實驗四

前處理

圖片轉換

防範過度擬合，新增額外轉換

1. ‘transforms.RandomVerticalFlip()‘隨機垂直翻轉的轉換，以增加數據的多樣性。
2. ‘transforms.ColorJitter(...)‘: 隨機調整圖像的亮度、對比度、飽和度和色調。
3. ‘transforms.RandomGrayscale(p=0.1)‘: 以 0.1 的概率將圖像轉換為灰度。
4. ‘transforms.RandomAffine(...)‘: 進行隨機仿射變換，這裡主要是平移。

訓練方法

使用 PyTorch 的 torch.optim .lr_scheduler.ReduceLROnPlateau 模塊。

1. ’min’: 監控的指標，這裡是最小化某個指標。
2. patience=5: 如果在 5 個 epoch 內指標沒有改善，則減少學習率。
3. factor=0.5: 學習率減少的倍數。

總結：

1. 訓練資料變得更多樣化能提升模型泛度，然而卻會損失訓練時的效率
2. 自動減低學習率對後期微調有不錯成效
3. 成效降低 0.6%

實驗結果:

測定獲取: 0. 786957 驗證準確度，對比訓練 0.67 準確度，測試 0.79107，過度擬合在此有所緩解，但是訓練的梯度變得相當難優化

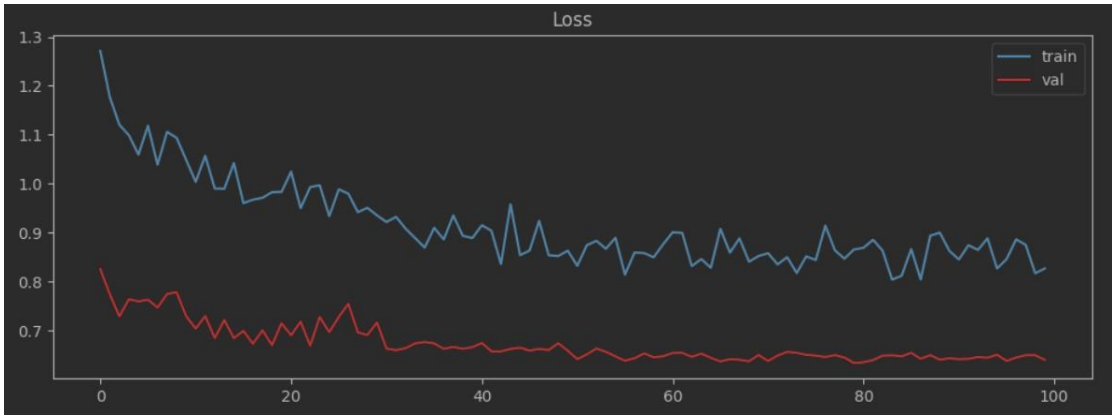

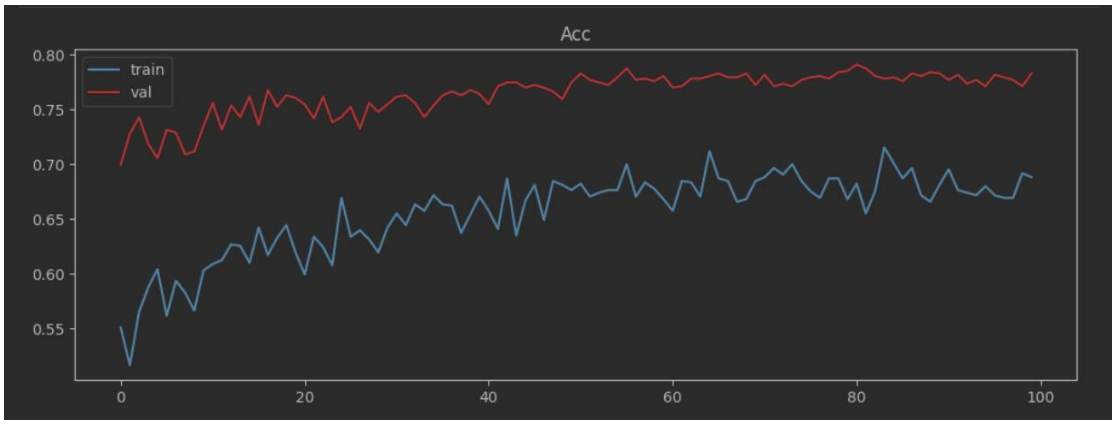

備註: 這是基於實驗二模型進行調整

實驗五

圖片轉換

防範過度擬合，新增額外轉換

1. 取消‘transforms.RandomGrayscale(p=0.1)‘
2. 取消‘transforms.RandomAffine(...)‘

模型設計

一、初始特徵提取

這一層用於對原始圖像進行初步的特徵提取。使用了 3 個通道（RGB）輸入和 32 個輸出通道。

二、IBConv Blocks With Squeeze-and-Excitation and Residual Connect

每個區塊都可能包含深度可分離卷積（Depthwise separable convolution）、Squeeze-and-Excitation（SE）模塊等。這些區塊有時會被重複使用，特別是當輸入和輸出通道數相同的時候。在 IBConv 區塊中，如果輸入和輸出通道數相同，添加一個殘差連接（Residual Connection）和 Dropout 層以防止過擬合。

三、Final Convolution

這一層將 80 個通道的特徵圖轉換為 1280 個通道。

四、Fully connected layers

取消 Dropout

訓練方法

1. 學習率改成 0.003
2. weight_decay 改成 1e-5

3. 在每個提升 valid accuracy 後降低 threshold 0.025

總結：

1. SE 使用可以提升準確度，但是使我的每個 epochs 多 25% 時間（約 10s 採用 3060 計算）
2. Residual 可以加強深層網路學習，不過對比 8 個 Block 與 15 個 Block 更深層網路準確度提升有限，推測可能是資料過少
3. 自動降低 threshold 可以在 Semi 提升些許準確度，且有持續提升空間
4. 在 Residual 卷積層使用 Dropout 比在全連接使用具有較好成效
5. 成效顯著提升 3.2%

實驗結果:

測定獲取: 0.827667 驗證準確度，對比訓練 0.870700 準確度，測試 0.81924，過度擬合出現在訓練階段，但是總成效提升

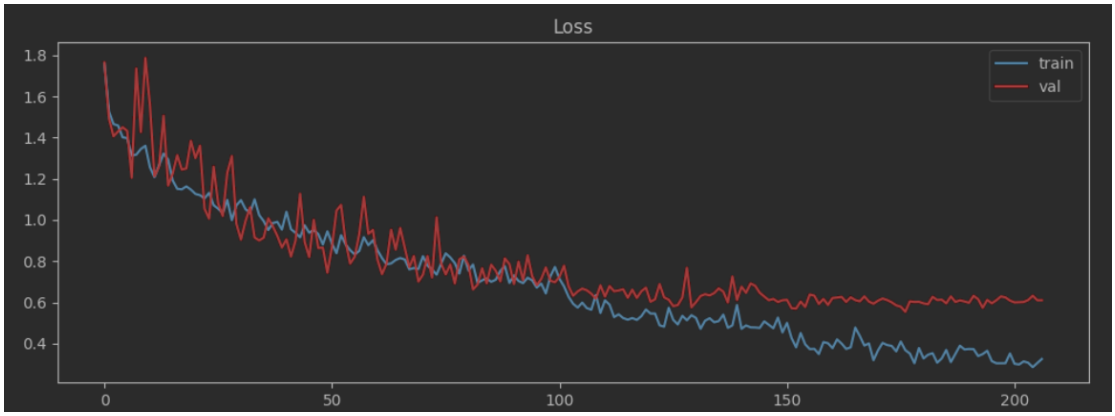

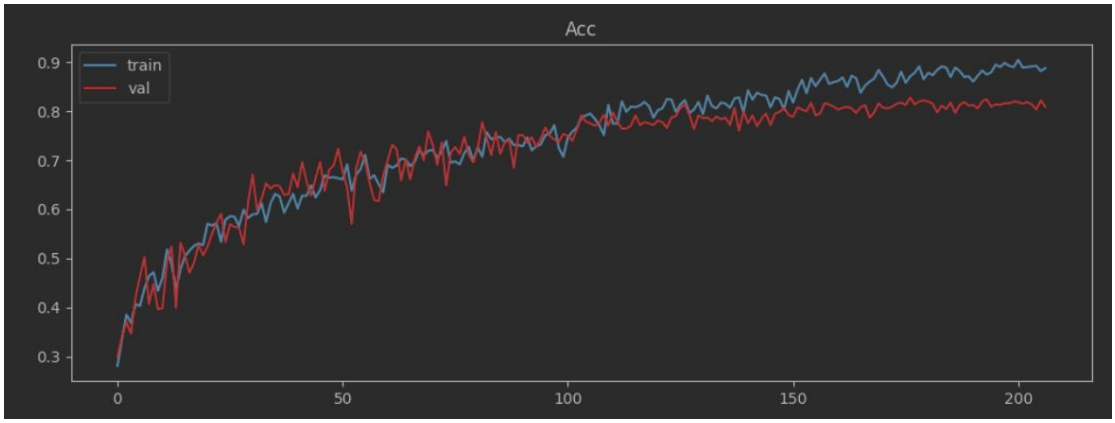

上方是 Block 8

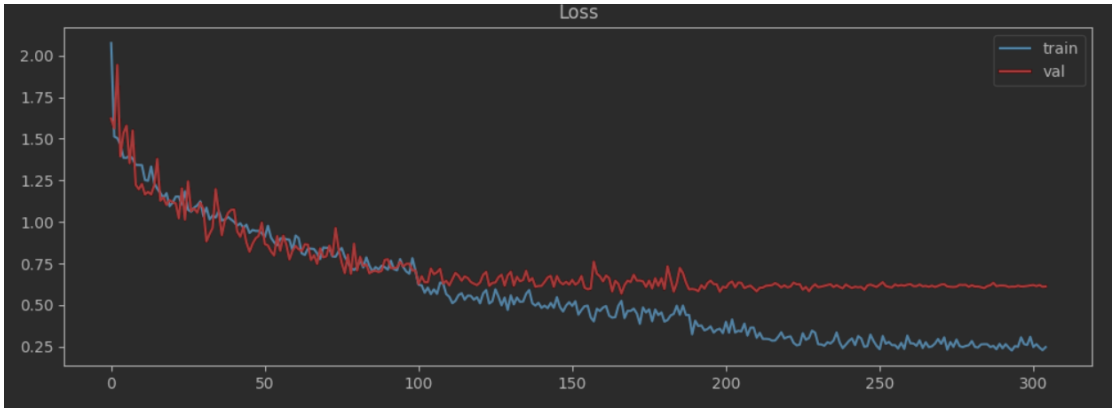

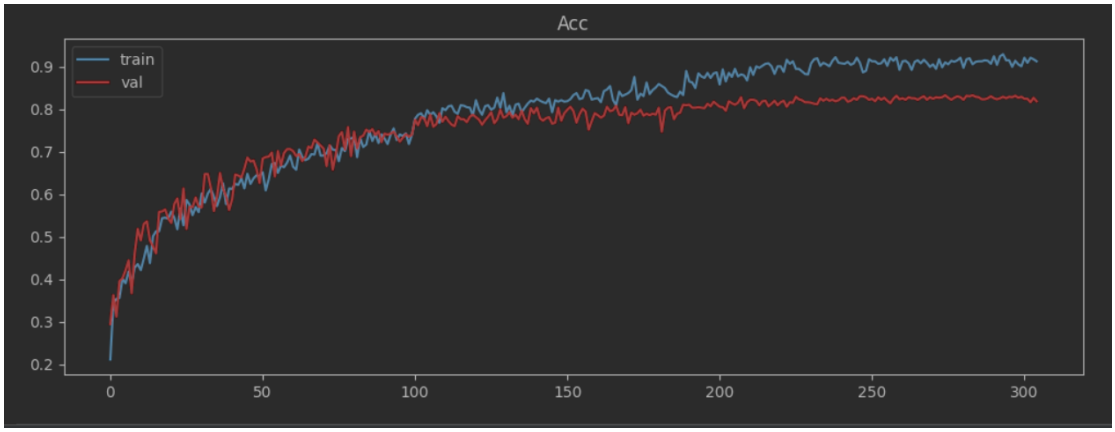

上方是 Block 11，在後期出現比較嚴重過擬合，但是 Valid 走輕微上升

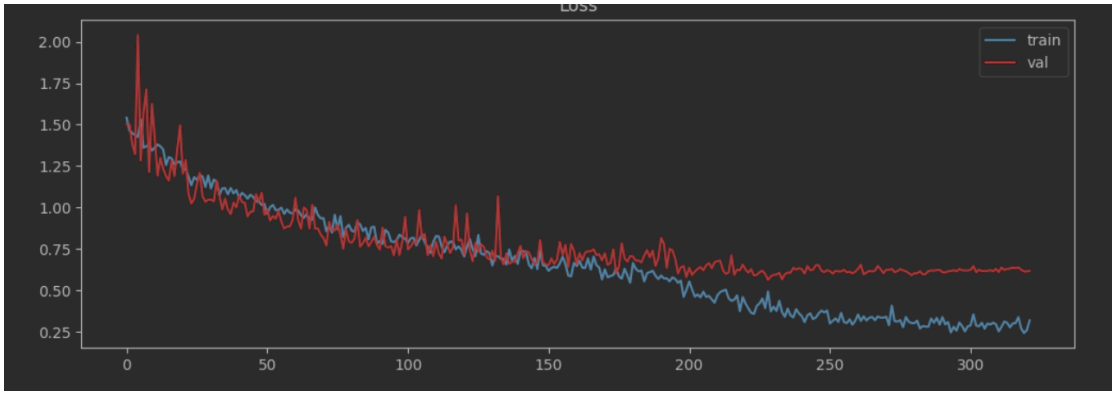

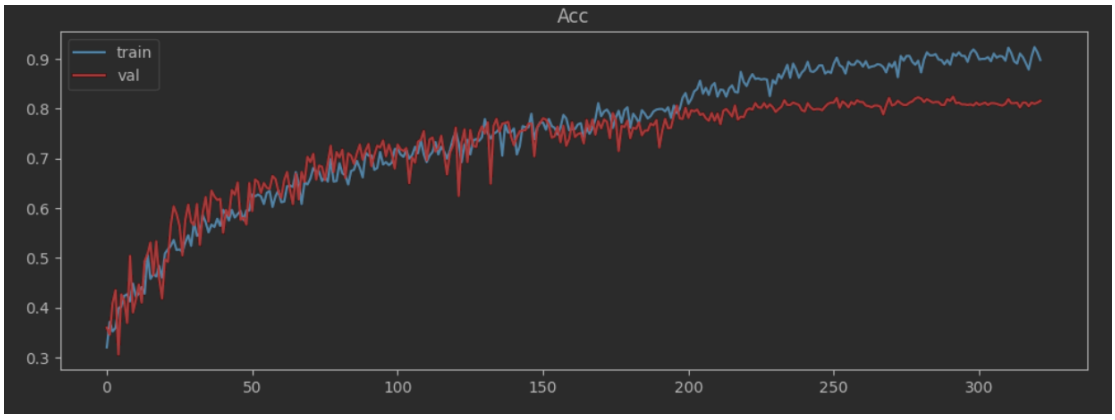

上方是 Block 15

實驗六

訓練方法

1. 新增 EMA 在 Semi-Supervise (ema_decay = 0.999)，不直接使用反向回饋，而是由學生反饋更新，具有較好穩定性
2. 將 Pseudo-Label 改成每個 epoch 都會更新，即便上回合已經被標定
3. 每次 epoch 結束時選擇較佳模型來預測下回合的 Persudo-Lable

總結：

我採用 EMA 與原始模型對比驗證準確度，發現這樣能使標籤在每 epoch 刷新時具有較好的品質穩定性，最終得到較好成效，不過很意外的是，我的 EMA Valid 準確度很長時間是低於原始模型，即便 loss 下降，推測可能是過度自信的 Pseudo-Label 會對模型有負面影響。

實驗結果:

測定獲取: 0.8262 驗證準確度，對比訓練 0.87380 準確度，測試 0.82629，對於末端訓練提升泛度有比較好幫助

實驗七

訓練方法

1. 新增 FixMatch 半監督演算法，模型以教師-學生的方式訓練，教師會用較簡單 Argumentation，而學生會作較複雜的 Argumentation，優化器對真實標籤與偽標籤使用不同 loss 來計算，如下圖
   - 真實標籤 loss function

$$\ell_s = \frac{1}{B}\sum_{b=1}^{B} \mathrm{H}(p_b, p_{\mathrm{m}}(y \mid \alpha(x_b)))$$

- 偽標籤 loss function

$$\ell_u = \frac{1}{\mu B}\sum_{b=1}^{\mu B} \mathbb{1}(\max(q_b) \geq \tau)\, \mathrm{H}(\hat{q}_b, p_{\mathrm{m}}(y \mid \mathcal{A}(u_b)))$$

總結：

驗證準確率有輕微上升，但是測試準確度保持一致。或許這方法在此模型成效有限

實驗結果:

測定獲取: 0.83317 驗證準確度，測試 0.82629，沒有顯著提升（訓練時我沒有紀錄混砸資料的準確度）

實驗八

訓練方法

1. 新增 EMA 在 Semi-Supervise（ema_decay = 0.999），不直接使用反向回饋，而是由學生反饋更新，具有較好穩定性
2. 將 Pseudo-Label 改成每個 epoch 都會更新，即便上回合已經被標定
3. 每次 epoch 結束時選擇較佳模型來預測下回合的 Persudo-Lable

總結：

我採用 EMA 與原始模型對比驗證準確度，發現這樣能使標籤在每 epoch 刷新時具有較好的品質穩定性，最終得到較好成效，不過很意外的是，我的 EMA Valid 準確度很長時間是低於原始模型，即便 loss 下降，推測可能是過度自信的 Pseudo-Label 會對模型有負面影響。

實驗結果:

測定獲取: 0.8262 驗證準確度，對比訓練 0.87380 準確度，測試 0.82629，對於末端訓練提升泛度有比較好幫助

實驗九

訓練方法

1. 使用 Temperature=2 在監督學習階段

總結：

沒有觀測刀顯著差異

實驗結果:

測定獲取: 0.83317 驗證準確度，測試 0.82629，沒有變化

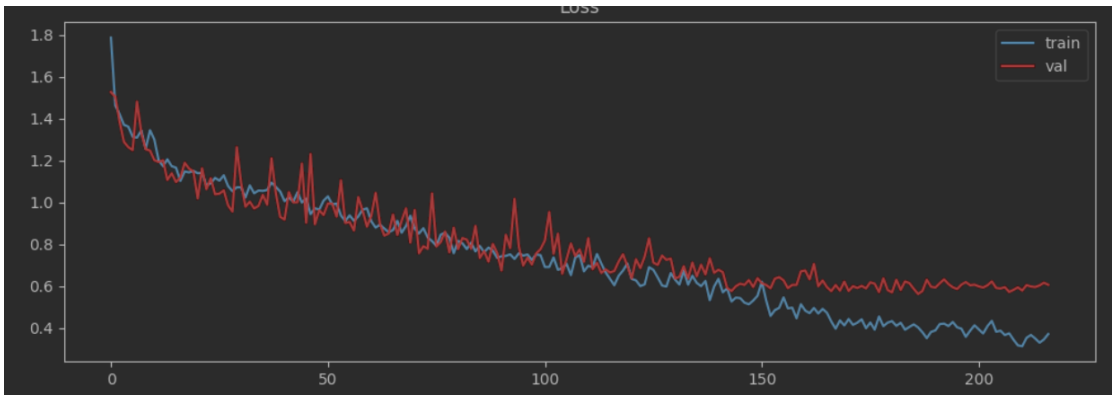

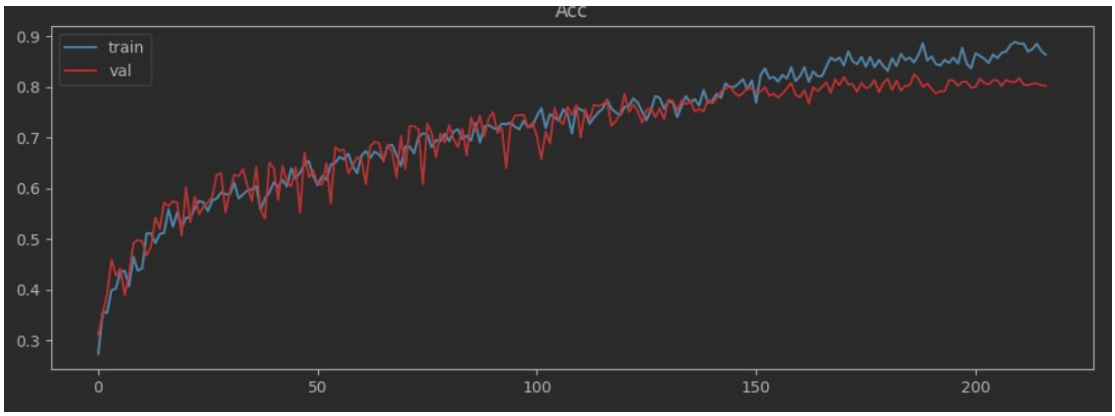

架構圖:

https://github.com/whats2000/Deep-Learning/blob/main/PyTorch/Class/pytorch103/model_architecture.png

程式原始碼:

https://github.com/whats2000/Deep-Learning/blob/main/PyTorch/Class/pytorch103/A3_semi_supervised_flower_classification.ipynb

資料參考:

不同類型卷積方塊設計方法:
https://github.com/FrancescoSaverioZuppichini/BottleNeck-InvertedResidual-FusedMBConv-in-PyTorch

Residual Inverted Bottleneck Convolution:
https://paperswithcode.com/method/inverted-residual-block

自動轉換選擇:
https://arxiv.org/pdf/1805.09501.pdf

關於 SE 使用:
https://hackmd.io/@machine-learning/HkH1jUArI

半監督策略 FixMatch:
https://arxiv.org/ftp/arxiv/papers/2001/2001.07685.pdf